

连续循环单元模型研究

摘要

循环神经网络为研究时间序列的重要工具。传统循环神经网络模型如 LSTM 和 GRU 无法对不规则时间序列进行建模从而会忽略掉被清除的不规则数据中隐藏的关键信息。常用于不规则时间序列研究的循环神经网络模型为运行时间较长的 Neural ODEs。本项目在以往循环神经网络的基础上提出连续循环单元模型(CRU)，研究主要目的为保证模型训练准确率的同时缩短模型运行时长。CRU 模型主要特征是利用线性 SDE 建立连续隐藏状态，使用连续-离散卡尔曼滤波器完成预测与更新步骤实现降噪功能。本项目重点研究 CRU 模型的内部机制，包括通过文献调研的方式研究 CRU 模型组件原理和具体作用流程、使用 CRU 模型与基线处理不规则时间序列完成插值、回归与外推任务并通过 CRU 与基线实验结果对比的方式对 CRU 模型性能进行评估。其次本项目使用参数化方案对 CRU 模型从方程表达能力与运行时间两方面进行优化，为后续针对 CRU 模型优化研究提供可行研究方向。最后本项目探求 CRU 模型的可行应用领域，拟定为投资市场交易物价格研究。

报告正文

(一) 立项依据与研究内容（建议 8000 字以内）：

1. 项目的立项依据（研究意义、国内外研究现状及发展动态分析，需结合科学研究发展趋势来论述科学意义；或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录）；




图 1 项目总技术路线图

1.1 研究背景

近年来，作为人工智能方法进行序列建模的重要手段之一，对于时间序列建模方向的研究愈发受到重视。其中，循环神经网络被视为建模时间序列数据的重要工具，具有重要的研究价值。循环神经网络衍生出了一种递归体系结构，最为重要的两个模型分别是长短期记忆网络（LSTM）和门控循环单元（GRU）。长短期记忆网络引入了额外的细胞状态和三个门控，门控循环单元的递归方式通过引入门控机制来更新隐藏状态，都有效地平衡了新信息与历史数据之间的关系。传统的 RNN 通常基于规则采样率对时间序列进行建模，而针对不规则时间序列采样的研究，提出了 Neural ODEs 模型。Neural ODEs 利用普通微分方程（ODE）来确定不规则观测之间的隐藏状态，并利用标准循环神经网络的门控机制进行参数更新。然而，Neural ODEs 模型的训练过程中需要使用数值 ODE 求解器，这会显著增加整体的训练时间。

基于这个问题，我们提出了连续循环单元模型（CRU），该模型使用线性随机微分方程（SDE）来控制不规则观测之间的潜在状态，并利用卡尔曼滤波器进行参数更新。通过摆脱对 ODE 求解器的依赖，我们减少了模型训练的时间成本。同时，CRU 模型利用 SDE 演变的潜在状态和卡尔曼滤波器在任意观测时间上最优地集成噪声观测值，从而有效解决了原有问题并保证了建模准确性。

1.2 研究意义

对于时间序列建模的研究中，不规则采样的处理和分析是非常重要的部分。常规的时间序列研究会将不规则采样数据进行清洗并在此基础上进行建模，无疑会遗漏关键信息。同时，在样本数量有限的情况下，模型最终训练效果堪忧。因此，在不规则时间序列建模中，对于处理不规则采样数据的研究具有重要的价值。同时，对于神经网络研究不规则时间序列，训练时间和模型训练准确率同样重要。缩短不规则时间序列建模的训练时间对于提高效率具有重要意义。

基于以上分析，本项目将聚焦于不规则时间序列建模与降低训练时间成本

问题。我们采用线性 SDE 状态空间模型与卡尔曼滤波器，这样做有以下三个优势：(1) 概率状态空间提供明确的不确定性概念，使得门控机制和预测的置信度评估成为不确定性驱动的过程；(2) 卡尔曼滤波器提供了线性滤波问题的已知最优解，在局部线性状态空间中，它是最优解决方案；(3) 在任何时间点，潜在状态都可以得到解析解，无需进行数值积分或变分近似。这些优势使得 SDE 和卡尔曼滤波器在不规则时间序列建模方面具有有效的优化能力，对于 CRU 机制的研究具有重要的价值。

1.3 国内外研究现状及发展动态分析

基于不规则时间序列的建模，连续时间循环神经网络已经开始对可训练权值的 ODE 管理系统与参数优化方案进行研究，为之后 Neural ODEs(神经常微分方程)、Neural SDEs 研究打下基础。Neural ODEs 是一种用于建模和处理序列数据的神经网络架构，结合了常微分方程(ODEs)和神经网络的概念，通过动态的隐藏状态演化过程，能够处理具有不规则时间间隔的序列数据。Lechner, M 等(2020)曾利用 ODE-LSTM 使模型适应不规则采样同时解决传统循环神经网络的梯度消失与梯度爆炸问题^[1]。Herrera, C 等(2021)提出新模型 NJ-ODE 解决不规则时间训练观测问题^[2]。Morrill, J 等(2021)提出 Neural RDEs 使用粗糙路径理论处理长时间序列解决 Neural CDEs(传统神经控制微分方程)处理长时间序列计算资源需求量大^[3]的关键问题，在模型中引入 log-ODE 算法^[3]。Neural ODEs 方法尚未解决的问题为需要依赖 ODE 求解器进行训练，无疑会提升整体训练时间，同时 Morrill, J 等(2021)发现 Neural ODEs 未产生更新机制使传入的观测值纳入潜在轨迹^[3]。作为 Neural ODEs 的随机模拟，Neural SDEs 利用通过神经网络实现参数化的 SDE（随机微分方程）定义潜在时间过程。Li, X 等(2020)提出处理随机微分方程的优化方法，分别为通过随机伴随梯度方法解决 SDEs 模型中梯度计算问题、通过虚拟布朗运动解决布朗运动增量信息存储过多问题与通过潜变量 SDE 模型高效逼近 SDE 中潜在变量分布^[4]。Deng, R 等(2020)提出新型连续随机过程建模方法，即使用动态归一化流构建富有表现力的时间序列模型处理异步时间序列数据生成无偏样本，随后 Deng, R 等(2021)在之前的基础上提出 CLPF 模型使用驱动随机微分方程的时间依赖

性正则化流，将连续潜在过程解码为可观察过程^[5, 6]。Neural SDEs 在潜在过程中容纳噪声，但通常依赖于变分近似和数值求解。

Transformer 为基于神经网络的序列模型，其原理为将序列编码与解码通过注意力机制提升模型训练速度。Horn, M 等(2020)提出 SEFT 模型通过引入集合函数作为分类器处理不规则时间序列，该模型可以处理大规模数据集并且拥有易于解释的特性^[7]。Shukla, S. N 等(2021)提出多时间注意力机制，将时间嵌入注意力机制处理传统循环神经网络解决长时间序列稀疏性和不规则性^[8]。Shukla, S. N 等(2021)比较基于 ODE 插值模型与注意力模型、插补方法与基于集合神经网络方法处理时间序列的优缺点^[9]。此类模型缺点为通常为大体量模型，为训练过程带来不便。




图 2 连续循环单元外文文献引用有向图

基于神经网络对于不规则时间序列的应用，梁宏涛等(2023)对 RNN、LSTM 与 GRU 有较为细致的总结并列举多种时间序列常见的研究方向，其中包括股票行情分析^[10]。李辉等(2022)利用 RF-LSTM 组合模型预测股票价格，并发现该组合模型与原有的 LSTM 预测模型相比提高了股票价格预测的准确率^[11]。张琳(2023)使用 LSTM 模型估计中国股票价格并对以往 LSTM 模型对股票价格

估计进行总结^[12]。相关研究证实 LSTM 模型对于股票价格的建模与预测有一定的合理性。

本项目在原有 Neural SDEs 的基础上摆脱对 ODE 求解器的依赖，通过封闭形式传播状态并进行端到端训练与原有的 Neural SDEs 加以区分，同时作为体量较小的模型拥有优于普通注意力机制的高性能计算特征。

参考文献

- [1] Lechner, M. and Hasani, R. Learning long-term dependencies in irregularly-sampled time series. *arXiv preprint arXiv:2006.04418*.2020.
- [2] Herrera, C., Krach, F, and Teichmann, J. Neural jump ordinary differential equations: Consistent continuous-time prediction and filtering. In *9th International Conference on Learning Representations*, 2021.
- [3] Morrill, J., Salvi, C, Kidger, P, and Foster, J. Neural rough differential equations for long time series. In *International Conference on Machine Learning*, pp. 7829–7838. PMLR, 2021.
- [4] Li, X, Wong, T.-K.L., Chen, R. T., and Duvenaud, D. Scalable gradients for stochastic differential equations. In *International Conference on Artificial Intelligence and Statistics*, pp.3870–3882.PMLR,2020
- [5] Deng, R, Chang, B., Brubaker, M. A., Mori, G., and Lehrmann, A. Modeling continuous stochastic processes with dynamic normalizing flows. In *Advances in Neural Information Processing Systems*, pp. 7805–7815, 2020.
- [6] Deng, R., Brubaker, M. A, Mori, G., and Lehrmann, A. M. Continuous latent process flows. In *Advances in Neural Information Processing Systems*, pp. 5162–5173, 2021.

- [7] Horn, M., Moor, M, Bock, C, Rieck, B, and Borgwardt, K. Set functions for time series. In *International Conference on Machine Learning*, pp. 4353–4363.PMLR, 2020.
- [8] Shukla, S. N. and Marlin, B. M. Multi-time attention networks for irregularly sampled time series. In *International Conference on Learning Representations*, 2021.
- [9] Shukla, S. N. and Marlin, B. M. A survey on principles, models and methods for learning from irregularly sampled time series. *arXiv preprint arXiv:2012.00168*, 2020.
- [10] 梁宏涛, 刘硕, 杜军威, 等. 深度学习应用于时序预测研究综述[J]. 计算机科学与探索, 2023,17(6):1285–1300.
- [11] 李辉, 化金金, 邹波蓉. 基于 RF-LSTM 组合模型的股票价格预测[J]. 河南理工大学学报 (自然科学版) , 2022,41(1):136–142.
- [12] 张琳. 基于人工智能的中国股票价格预测与异质性研究[J]. 暨南学报(哲学社会科学版), 2023,45(03):123–132.

2. 项目的研究内容、研究目标，以及拟解决的关键科学问题（此部分为重点阐述内容）；




图 3 项目总体研究内容框架

本项目主要提出 CRU 模型用于优化传统的 LSTM 等递归架构模型，旨在提高模型训练速度的同时保证模型训练准确率。由于 CRU 在方程表达能力存在提升空间，并且卡尔曼增益计算与预测步骤中的矩阵指数会延长模型整体训练时间，因此，本项目还提出了通过参数化的方式在 CRU 模型方程表达和速度方面进行相应优化。最终，本项目会依照传统 LSTM 相关应用的经验，寻找 CRU 可行的应用方向并进行相关应用研究。

研究内容 1：CRU 模型内部机制研究，为后续对 CRU 模型的进一步优化提供理论基础。

研究内容 2：CRU 模型方程表达能力优化——局部线性状态转换，更准确地捕捉数据的变化规律，为构建 f-CRU 模型做准备。

研究内容 3：CRU 模型计算速度与稳健性优化——f-CRU 模型，为后续应用于大规模数据和实时预测场景提供实用性基础。

研究内容 4：CRU 在投资市场中应用。

2.1 主要研究内容

研究内容 1: CRU 模型内部机制研究。

(1) 基本方程

隐藏状态假设方程如式(1):

$$dz = Azdt + Gd\beta \quad (1)$$

在完成隐藏状态的假设之后对序列进行顺序处理，即进行编码与解码操作。

编码操作如式(2):

$$\text{encoder:} \quad [y_t, \sigma_t^{\text{obs}}] = f_{\theta}(x_t) \quad (2)$$

待序列完成编码后进行顺序处理。先验分布式(又名预测步骤)如式(3):

$$[\mu_t^-, \Sigma_t^-] = \text{predict}(\mu_{\tau(t)}^+, \Sigma_{\tau(t)}^+, t - \tau(t)) \quad (3)$$

后验分布(又名更新步骤)如式(4):

$$[\mu_t^+, \Sigma_t^+] = \text{update}(\mu_t^-, \Sigma_t^-, y_t, \sigma_t^{\text{obs}}) \quad (4)$$

最终使用解码器进行解码得到输出值，如式(5):

$$\text{decoder:} \quad [o_t, \sigma_t^{\text{out}}] = g_{\theta}(\mu_t^+, \Sigma_t^+) \quad (5)$$

(2) 函数解析

式(1)进行隐藏状态假设，用于连续状态空间模型估计。隐藏状态根据线性随机微分方程演变，以便之后的编码操作将观测数据映射到由线性随机微分方程（SDE）控制的潜在空间。其中 A 为定常转移矩阵， $A \in \mathbb{R}^{M \times M}$ ， G 为扩散系数， $G \in \mathbb{R}^{M \times B}$ ，集成变量 $\beta \in \mathbb{R}^B$ 为带有扩散矩阵的布朗运动过程。

式(2)用于编码操作。编码公式中，在每个时间点 t 时，将观测值 x_t 输入神经网络编码器 f_{θ} 中，生成潜在观测变量 y_t 与元素潜在观测噪声 σ_t^{obs} ，目的是产生潜在观测值与元素潜在观测噪声。

式(3)进行先验分布(预测步骤)，首先假设观测时间 t 之前最新观测时间 $\tau(t)$ 中的后验参数为 $\mu_{\tau(t)}^+$ 与 $\Sigma_{\tau(t)}^+$ ，之后将此后续参数带入预测步骤得到先验参数 μ_t^- ， Σ_t^- 。预测步骤的基本原理是式(1)。

式(4)进行后验分布(更新步骤), 将先验参数带入更新步骤得到后验参数 μ_t^+ , Σ_t^+ 。更新步骤的具体原理是, 通过贝叶斯推导得到 t 时刻的后验参数。

式(5)利用解码器将后验参数映射到期望的输出空间。解码公式中, 在神经网络解码器 g_θ 中输入后验参数 μ_t^+ 与 Σ_t^+ , 得到输出。

研究内容 2: CRU 模型方程表达能力优化——局部线性状态转换。

深度卡尔曼模型通过局部线性转换增加建模灵活性, CRU 模型同样可以使用局部线性转换增加建模灵活性, 同时确保预测与更新步骤的封闭式计算。

(1) 基本方程

使用参数化策略提升方程表达能力如式(6):

$$A_t = \sum_{k=1}^K a_t^{(k)} A^{(k)}, \quad a_t = \omega_\psi(\mu_t^+) \quad (6)$$

(2) 函数解析

式(6)显示将 t 时刻的转移矩阵 A_t 设计成由 K 个参数化基矩阵的加权平均值。加权系数 $a_t^{(k)}$ 是从 t 时刻后验均值 μ_t^+ 通过具有 SoftMax 输出的神经网络 ω_ψ 得到。为减少参数数量, 每个基矩阵都由四个带宽相同的带状矩阵组成。

研究内容 3: CRU 模型计算速度与稳健性优化——f-CRU 模型。

CRU 模型的主要运行时间受卡尔曼增益计算中的矩阵反演和预测步骤中的矩阵指数共同影响。两者都用于预测步骤中后验参数的计算。由于预测步骤中同时使用矩阵指数, 所以对于 CRU 模型计算速度的优化不可通过单纯简化矩阵。在通过对状态协方差和观测模型使用因式分解的假设进行矩阵反演简化的基础上, 本项目提出通过只允许交换和对称基矩阵 $A^{(k)}$ 具有相关特征的空间, 从而避免矩阵指数运算的解决方案。

(1) 基本方程

经计算简化后的先验参数均值如公式(7)所示:

$$\mu_t^- = E \exp((t - \tau(t)) \sum_{k=1}^K a^{(k)} D^{(k)}) E^T \mu_{\tau(t)}^+ \quad (7)$$

经计算简化后先验参数方差如公式(8)所示:

$$\Sigma_t^- = E \Sigma_t^w E^T \quad (8)$$

(2) 函数解析

假设对角基矩阵 $\{A^{(k)}\}_{k=1 \cdots K}$ 拥有相同的正交特征向量。对于 $k \in \{1 \cdots K\}$, $A^{(k)} = E D^{(k)} E^T$, 其中 $D^{(k)}$ 作为对角矩阵, 其第 i 个对角线元素为 $A^{(k)}$ 对应于 E 的第 i 列特征向量的特征值。

式(7)使用 E 对潜在状态 z_t 进行基变换, 其中 $\exp(.)$ 为元素指数函数。

式(8)中同样使用 E 对潜在状态 z_t 进行基变换, 其中变换后状态向量 w 的 SDE 有对角跃迁的 D , 计算投影状态空间在 t 时间的协方差 Σ_t^w 后代入生成先验协方差。

研究内容 4: CRU 在投资市场中应用。

参考 LSTM 模型在股票市场的应用, 本项目分别利用 CRU 模型和 LSTM 模型预测投资市场价格波动。研究对象选择金价市场、股票投资市场与虚拟货币市场。通过对比两种模型的价格预测的准确率, 判断 CRU 模型在投资市场价格预测这类应用场景中是否合适。

2.2 研究目标

(1) 连续循环单元模型理论框架

CRU 基于 RNN 研究的基础提出了使用 SDE 模型和卡尔曼滤波器替代原先的 Neural ODEs 模型的方式。使用 Neural SDEs 无法实现的封闭式训练, 使神经网络在不规则时间序列研究方面摆脱对原有 Neural ODEs 中 ODE 求解器的依赖, 同时保证了模型训练的准确率与训练速度, 为循环神经网络研究不规则时间序列提供新研究方向——连续循环单元模型, 为 SDE 模型与卡尔曼滤波器在循环神经网络的应用方法提供了理论证明。

(2) 计划实验方法

本项目计划通过实验对于 CRU 模型的训练结果进行评估。研究中将使用三个数据集进行 CRU 模型的建模评估任务, 这三个数据集分别是: 显示一个钟摆

在 50 个不规则时间步上状态的钟摆图像数据集、包含降水量等五个变量的美国历史气候网络数据集和记录 8000 名重症监护病房患者前 48 小时的 41 项测量数据的电子健康数据集。实验将利用三种数据集研究三个任务：插值任务、回归任务和外推任务，并将 CRU 模型的训练结果与其他模型进行比较和评估。其中，钟摆图像数据集将经过特殊处理用于插值任务和回归任务的研究，而美国历史气候网络数据和电子健康数据将经过数据处理后用于外推任务的研究。设立插值任务命令模型基于观测值的子集学习数据潜在动态；设立回归任务并要求模型从系统噪声中进行图像预测；设立外推任务从数据前半部分的观测中学习动态预测剩余序列。与 CRU 模型对比的基线模型包括 RNN 架构、Neural ODEs 模型、Transformer 注意力机制。实验的重点将在比较 CRU 模型与基线模型在模型训练准确率和速度方面的优劣。

（3）连续循环单元模型应用

利用本项目提出的 CRU 模型，将对黄金市场、股票市场和虚拟货币市场的价格进行建模，并得出相关预测。通过与其它模型进行结果对比，展示本项目提出模型在预测准确率与预测速度方面的优势。这项研究为 CRU 模型在投资市场中的应用提供了思路，并具体展示了 CRU 模型在风险高、收益高、变动快、投资需求丰富的投资市场中的应用价值。

2.3 拟解决的关键科学问题

（1）CRU 模型内部机制理论研究及 CRU 模型性能评价

本项目主要研究 CRU 模型具体内部机制，并通过与其它基线包括 NN 架构、Neural ODEs 模型、Transformer 注意力机制进行比较，综合评估 CRU 模型性能。CRU 模型的开发使得新模型兼具神经网络用于特征提取能力和概率状态空间模型的优点。CRU 通过连续-离散卡尔曼滤波器构建不规则时间序列观测模型，为循环神经网络实验研究不规则时间序列提供了预测精度高、训练速度相对较快的可行方案。主要研究挑战是 CRU 模型对于不规则时间序列的处理原理。

（2）连续-离散卡尔曼滤波器限制模型表现能力

连续-离散卡尔曼滤波器的线性假设是有利的，因为此滤波器可以进行最优封闭式计算。然而，连续-离散卡尔曼滤波器对模型的表现能力有一定的限制。为了缓解这个问题，CRU 模型的编码器与解码器在一定程度上可以提高连续-

离散卡尔曼滤波器的表达能力。具体而言，通过局部线性模型转换的参数化方案可以增加 CRU 模型的建模灵活性，从而提升其表达能力。这项研究为后续 CRU 模型优化提供了可行的方向。

(3) 潜在状态维数影响矩阵反演与矩阵指数运行时间

CRU 模型中潜在状态维数会影响预测步骤中矩阵反演和更新步骤中矩阵指数的计算，从而影响整体模型的运行时间。为了减少运行时间，可以采取简化运算过程的方法。具体而言，在状态协方差和观测模型中使用基矩阵参数化替代指数矩阵运算，可以简化运算步骤。这样的参数化方案可以帮助简化 CRU 模型，从而减少运行时间。在解决这个问题时，我们面临的研究挑战是如何选择合适的参数化方案来简化 CRU 模型。

(4) 通过模型特点合理应用迎合投资市场需求

CRU 模型具有较高的建模准确性。在应用该模型时，主要的研究挑战是如何将 CRU 模型与投资市场需求相结合。为了解决这个问题，我们可以借鉴已有的投资市场价格预估模型，例如 LSTM 等模型，并将预测准确率较高的 CRU 模型应用到投资市场价格预测领域。这样的应用研究为后续 CRU 模型的应用提供了可行的研究方向。

3. 拟采取的研究方案及可行性分析（包括研究方法、技术路线、实验手段、关键技术等说明）；




图 4 连续循环单元研究技术路径图

3.1 研究方案与技术路线

3.1.1 连续循环单元模型研究

本项目重点研究 CRU 模型在插值任务、回归任务和外推任务中的不规则时间序列建模的表现情况。

数据集处理 数据集通过处理，使处理后的数据集符合任务要求，如钟表图片数据集中二分之一的帧被随机删除、设立标签标记钟摆图片摆动的角度并且通过噪声损坏原有图像。其它数据集则因为数据调查中本身的不足导致数据缺失符合不规则采样要求，如美国历史气候数据与电子健康数据，其中美国历史气候数据又进行子采样与随机删除 20%测量值的处理，两个数据集各自分为 20%测试集与 80%训练集并提取 25%的数据用于模型验证。

CRU 模型内部机制研究思路

本项目对于 CRU 模型内部机制研究包括分析模型架构与组件、研究算法实现细节并实验研究对模型建模性能进行评估。

对于模型架构与组件的分析方面本研究拟定使用查找外文文献的方式进行总结了解模型基础架构与组件的原理。

对于研究算法实现细节研究方面本研究拟定依据原有的研究提出 CRU 模型具体算法流程并进行算法流程的优化。其中算法流程的优化思路在下文解决连续-离散卡尔曼滤波器限制模型表达问题以及解决矩阵反演与矩阵指数问题两分会进行详细介绍。

对于模型建模性能评估研究方面本研究设置三种不规则时间序列处理任务用于测试 CRU 模型建模能力，同时设置基线与 CRU 模型进行对比研究。**插值任务**目标为通过已知数据补全未知数据，本项目实验中具体操作为通过输入部分钟摆图片帧获取最终完整的钟摆图像序列；**回归任务**目标为通过已有数据预测未来数据，本项目实验中具体操作是通过输入带有噪声影响的不规则钟摆图像数据帧，预测之后钟摆摆动角度；**外推任务**目标为通过已有不规则时间序列预测未来数据变动趋势，本项目实验中具体操作为利用电子健康数据从患者前 24 小时数据中推导患者后 48 小时产生数据。问题实验目的为研究部分观察输入中的 CRU 门控机制，需要通过五维美国历史天气数据集执行外推任务，在实验过程中明确控制部分可观测性程度进行部分可观测性实验。

解决连续-离散卡尔曼滤波器限制模型表达问题的研究思路

连续-离散卡尔曼滤波器存在限制方程表达能力问题。本项目提出两种解决方案，其一为利用 CRU 模型内部机制自带的编码器与解码器对数据进行加工处理缓解连续-离散卡尔曼滤波器对方程表达能力的限制，其二为使用局部线性状态转化的参数化方案提高模型建模灵活性。

解决矩阵反演与矩阵指数问题的研究思路

已有参数化方案为对状态协方差与观测模型 H 使用因式分解假设，通过简化矩阵反演提高速度与稳定性。CRU 模型拥有额外的技术瓶颈，即预测步骤中计算先验参数所需矩阵指数。本项目提出 f-CRU 模型简化矩阵反演同时通过只允许交换具有相关特征空间的对称基矩阵 $A^{(k)}$ 的方式绕过矩阵指数计算，使得矩

阵指数运行时间从复杂度 $O(n^3)$ 简化至矩阵乘法和元素运算。f-CRU 模型在牺牲一定建模灵活性的前提下提升了模型整体计算速度。

对于 CRU 模型在投资市场应用研究的研究思路

通过寻找合适的投资市场数据集，拟定为实时黄金价格、印度雀巢 Nestle 股票价格和虚拟货币价格三个数据集，每个数据集都有日期、收盘价、成交量、开盘价、最高价与最低价七维数据。通过将三个数据集进行预处理区分训练集和测试集实现外推任务据此评估 CRU 模型在不确定性强、风险高、利润高的投资市场估计投资交易物价格的任务中是否存在高准确率、低运行时间的优势。在投资市场应用中会将 CRU 模型运行结果与其它基线运行结果进行对比。

基线——RNN 架构、Neural ODEs 和 Transformer 注意力模型

与 CRU 模型进行对比的基线包括 RNN 架构、Neural ODEs 和 Transformer 注意力模型机制。本项目研究中使用的 RNN 架构模型包括两条基线，为具有离散隐藏状态的 GRU 模型与循环卡尔曼网络(RKN 模型)。其中较为特殊的基线为可在观测值间使用可训练的隐藏状态衰减处理连续时间尺度上的不规则输入的 GRU-D 模型。本项目研究中使用 Neural ODEs 包括观测时间 ODE 定义的连续隐藏状态动态与经典 RNN 交替的 ODE-RNN 模型，使用 ODE-RNN 作为识别网络来推断其潜在状态的初始值并用 ODE 对状态演化进行建模的 Latent ODE 模型，将 GRU 的连续时间版本与离散更新网络相结合的 GRU-ODE-B 模型。本项目研究使用的注意力模型为在编码器和解码器中使用多时间注意力模块的 mTAND。

3.1.2 连续循环单元技术路线

连续循环单元方法主要原理为利用线性 SDE 设立隐藏层。进行编码操作后通过先验分布进行先验参数计算，再利用先验参数通过连续-离散卡尔曼滤波加权得到后验参数。最后将数据解码操作得到输出值。

隐藏状态假设：首先假设一个隐藏状态，用于连续状态空间模型估计，如公式（1）所示：

$$dz = Azdt + Gd\beta \quad (1)$$

此隐藏状态根据线性随机微分方程演变以便于之后的编码操作将观测数据映射到由线性随机微分方程（SDE）控制的潜在空间。其中 $\mathbf{A}$ 为定常转移矩阵且 $\mathbf{A} \in \mathbb{R}^{M \times M}$ ， $\mathbf{G}$ 为扩散系数且 $\mathbf{G} \in \mathbb{R}^{M \times B}$ ，集成变量 $\beta \in \mathbb{R}^B$ 为带有扩散矩阵 $\mathbf{Q} \in \mathbb{R}^{B \times B}$ 的布朗运动过程， $\mathbf{z} \in \mathbb{R}^M$ 为根据线性 SDE 发展的连续潜在状态（隐藏状态），具有连续动力。CRU 模型假设高斯观测模型 $\mathbf{H} \in \mathbb{R}^{D \times M}$ 产生噪声潜在观测值，其中 σ_t^{obs} 表示观测噪声，如公式(9)：

$$y_t \sim \mathcal{N}(\mathbf{H}\mathbf{z}_t, (\sigma_t^{\text{obs}})^2 \mathbf{I}) \quad (9)$$

编码操作：编码公式中在每个时间点 t 时将观测值 x_t 输入至神经网络编码器 f_θ 中，生成潜在观测值 y_t 与元素潜在观测噪声 σ_t^{obs} ，使用目的为产生潜在观测值与元素潜在观测噪声，如公式(2)：

$$\text{encoder: } [y_t, \sigma_t^{\text{obs}}] = f_\theta(x_t) \quad (2)$$

预测步骤：先验分布公式如式(10),用 $y_{<t}$ 表示观测时间 t 之前的所有潜在观测值的集合， $y_{\leq t}$ 表示观测时间 t 之前包括 y_t 的所有潜在观测值的集合。先验分布中的参数 (μ_t^-, Σ_t^-) 是通过反应式传播隐藏状态来计算。

$$\text{prior: } p(\mathbf{z}_t | y_{<t}) = \mathcal{N}(\mu_t^-, \Sigma_t^-) \quad (10)$$

假设观测时间 t 之前最新观测时间 $\tau(t)$ 中的后验参数 $\mu_{\tau(t)}^+$ 与 $\Sigma_{\tau(t)}^+$ ，目的为计算 t 时刻先验参数，如式(11)：

$$\tau(t) := \max \{t' \in T \text{ s.t. } t' < t\} \quad (11)$$

利用线性 SDE 在隐藏状态中求时刻 t 时的解，得到 $\mathbf{z}_t$ ，如式(12)：

$$z_t = \exp(A(t - \tau(t)))z_{\tau(t)} + \int_{\tau(t)}^t \exp(A(t-s))Gd\beta_s \quad (12)$$

带入假设的时刻 $\tau(t)$ 的后验参数得到先验步骤中得出的先验参数均值 (μ_t^-) 与协方差 (Σ_t^-)。其中 $\exp(\cdot)$ 为矩阵指数。具体表达式如式(13)、式(14):

$$\mu_t^- = \exp(A(t - \tau(t)))\mu_{\tau(t)}^+ \quad (13)$$

$$\begin{aligned} \Sigma_t^- &= \exp(A(t - \tau(t)))\Sigma_{\tau(t)}^+ \exp(A(t - \tau(t)))^T \\ &+ \int_{\tau(t)}^t \exp(A(t-s))GQG^T \exp(A(t-s))^T ds \end{aligned} \quad (14)$$

最终预测步骤总结如式(3):

$$[\mu_t^-, \Sigma_t^-] = \text{predict}(\mu_{\tau(t)}^+, \Sigma_{\tau(t)}^+, t - \tau(t)) \quad (3)$$

更新步骤：更新步骤原理为输入先验参数通过贝叶斯推导得到 t 时刻后验参数过程。首先使用贝叶斯定理更新先验分布。后验分布参数正比于 t 之前所得先验分布参数与观测值 y_t 的乘积。如式(15)所示:

$$p(z_t | y_{\leq t}) \propto p(y_t | z_t) p(z_t | y_{< t}) \quad (15)$$

根据高斯函数，后验分布符合高斯函数性质，得到后验参数。如式(16)、式(17)所示:

$$\mu_t^+ = \mu_t^- + K_t(y_t - H\mu_t^-) \quad (16)$$

$$\Sigma_t^+ = (I - K_t H) \Sigma_t^- \quad (17)$$

其中式(16)中 K_t 为卡尔曼增益，是先验与观察之间的门，将观测噪声与先前不确定性进行对比，观测噪声水平低时就会有较高的卡尔曼增益。如式(18)所示：

$$K_t = \Sigma_t^{-1} H^T (H \Sigma_t^{-1} H^T + \Sigma_t^{\text{obs}})^{-1} \quad (18)$$

最终更新步骤总结如式(4)：

$$[\mu_t^+, \Sigma_t^+] = \text{update}(\mu_t^-, \Sigma_t^-, y_t, \sigma_t^{\text{obs}}) \quad (4)$$

解码操作：解码公式中在神经网络解码器 g_θ 中输入后验分布得出的均值 μ_t^+ 与方差 Σ_t^+ 进行相应映射。如式(5)所示：

$$\text{decoder:} [\mu_t^-, \sigma_t^{\text{out}}] = g_\theta(\mu_t^+, \Sigma_t^+) \quad (5)$$

局部线性状态转化操作：本操作目的为提高状态方程表达能力。增加 CRU 建模灵活性，同时保持原先的预测、更新步骤的封闭式计算。将 t 时刻的转移矩阵 A_t 设计成由 K 个参数化基矩阵的加权平均值。加权系数 $\alpha_t^{(i)}$ 是从 t 时刻后验均值 μ_t^+ 通过具有 SoftMax 输出的神经网络 ω_ψ 得到。为减少参数数量，每个基矩阵由四个带宽为 b 的带状矩阵得到。本项目同时假设一个对角扩散矩阵 Q ，其对角元素的向量 q 为定常可学习参数。隐藏状态式(1)中扩散系数 G 固定于单位矩阵中，即 $G = I$ 。此为非限制性，因为 G 可与预测步骤式(9)中向量 q 结合出现，并且不受约束。

$$A_t = \sum_{k=1}^K \alpha_t^{(k)} A^{(k)}, \quad \alpha_t = \omega_\psi(\mu_t^+) \quad (6)$$

f-CRU 参数化方案操作：CRU 模型优化生成 f-CRU 模型主要原理为进行简化矩阵反演与参数化基矩阵 $A^{(k)}$ 。

假设对角基矩阵 $\{A^{(k)}\}_{k=1 \cdots K}$ 拥有相同的正交特征向量。对于 $k \in \{1 \cdots K\}$ 条件下, $A^{(k)} = E D^{(k)} E^T$ 。其中 $D^{(k)}$ 作为对角矩阵, 其第 i 个对角线元素为 $A^{(k)}$ 对应于 E 的第 i 列特征向量的特征值。

使用 E 对潜在状态 z_t 进行基变换时, 变换后状态向量 w 的 SDE 矩阵拥有对角跃迁矩阵 D , 其中 $\exp(\cdot)$ 为元素指数函数。 t 时刻先验均值化简如式(7):

$$\mu_t^- = E \exp((t - \tau(t)) \sum_{k=1}^K \alpha^{(k)} D^{(k)}) E^T \mu_{\tau(t)}^+ \quad (7)$$

计算投影状态空间在时间 t 的协方差 Σ_t^- , 将协方差映射回原始基, 产生时间 t 的先验协方差如式(8):

$$\Sigma_t^- = E \Sigma_t^w E^T \quad (8)$$

模型训练操作: CRU 模型可训练参数包括神经网络编码器参数 θ 与神经网络解码器参数 ϕ 以及局部线性 SDE 相关参数等。

训练参数方法为创建序列数据集, 每个输入 x_T 对应输出 s_T 。对于实值输出, 目标函数为基本真值 s_t 的高斯负对数似然, 并由单个样本给出, 其中 o_t 和元素不确定度估计 σ_t^{obs} 为 CRU 模型计算得到的输出值, 具体公式如式(19):

$$L(s_T) = -\frac{1}{N} \sum_{t \in T} \log N(s_t | o_t, (\sigma_t^{\text{obs}})^2) \quad (19)$$

对于二进制输出, CRU 模型在伯努利负对数似然上训练, 本项目将损失用于灰度图像的输入, 其中输出 s_t 为 $[0, 1]$ 范围内的 D_o 个像素值, 具体公式如式(20):

$$L(s_T) = -\frac{1}{N} \sum_{t \in T} \sum_{i=1}^{D_o} s_t^{(i)} \log(o_t^{(i)}) + (1 - s_t^{(i)}) \log(1 - o_t^{(i)}) \quad (20)$$

3.1.3 连续循环单元理论分析




图 2 CRU 模型原理

由图 2 可知 CRU 模型基本原理。将观测值 x_t (绿色曲线部分)通过编码器生成对应的潜在观测值 y_t 和噪声 σ_t^{obs} (橙色曲线部分)，通过先验分布计算对应状态的均值与协方差后(红色空心点)进行贝叶斯定理更新的后验分布得到相应的后验参数(红色实心点)，最后通过解码器生成输出值 o^T 。

CRU 模型内部隐藏状态如图 3。假设本次观测时刻为 t ， t 之前时间为 $\tau(t)$ ，获得 $\tau(t)$ 时刻后验参数并输入到预测步骤进行先验分布操作得到 t 时刻先验参数。同时 t 时刻观测值 x_t 通过编码器生成潜在观测值与噪声。潜在观测值与噪声结合 t 时刻先验参数 μ_t^-/Σ_t^- 输入至更新步骤得到后验参数 μ_t^+/Σ_t^+ 。一方面，后验参数通过解码器生成输出值表示模型，另一方面后验参数向之后时间传递行成记忆帮助下一观测时间生成先验参数。CRU 模型在继承 LSTM 与 GRU 遗忘部分数据的优势后又发展出利用线性 SDE 构建隐藏层、借助卡尔曼滤波器实现预测步骤与更新步骤的创新，使得 CRU 模型具有不借助 ODE 求解器进行封闭式计算、运行时间相较于 Neural ODEs 较短、模型预测准确率高、摆脱变分近似方法等优势。




图 3 CRU 模型内部隐藏状态

3.2 关键技术和实验手段

本节将对每个研究内容中使用到的关键技术，以及相关实验验证方法进行总结，在表 1 中进行总结。

表 1: 关键技术及实验方法总结

研究内容	核心技术	实验方法
1. CRU 模型方法	● 连续动力学理论 ● 贝叶斯定理 ● 高斯噪声观测模型	● 理论证明 ● 实验研究 ● 数值仿真
2. 局部线性状态转移	● 基矩阵加权平均法	● 理论证明 ● 实验研究
3. f-CRU 模型方法	● 线性系统理论 ● 矩阵变换处理方法	● 理论证明 ● 实验研究 ● 数值仿真
4. CRU 模型投资市场应用	● 高斯负对数似然函数 ● 伯努利负对数似然函数	● 数值仿真 ● 实验研究

(1) CRU 模型方法

本项目在研究 CRU 模型原理的过程中包含三个核心步骤：第一，在预测步骤中的核心理论，通过线性 SDE 构建隐藏层，实现隐藏状态计算，线性随机微分方程使得隐藏状态拥有连续动力性。预测步骤基于连续动力学理论完成先验步骤。第二，更新步骤中的核心理论。更新步骤中使用贝叶斯定理对随机过程进行预测和估计。预测步骤与更新步骤同为卡尔曼滤波器关键概率分布。第三，

在分析过程中必须引入的高斯噪声观测模型。高斯观测模型是指对系统状态或变量的观测数据服从高斯分布的模型，在本研究中利用高斯噪声模型考虑元素不确定性增加模型训练结果可信度。

本研究将以理论分析为主，利用插值、回归和外推三种任务对 CRU 模型进行实验研究与数值仿真。通过将 CRU 模型与其它基线进行比较以此达到评估 CRU 模型性能的功能。

（2）局部线性状态转化

本研究通过基矩阵加权求平均值的方法提高建模灵活性，为实现局部线性状态转化的参数化方案。连续-离散卡尔曼滤波器只接受线性化假设、噪声预想符合高斯分布的特点使得模型表达能力受限制，利用局部线性状态转移模型将现实中非线性数据转化为可被卡尔曼滤波器处理的多个线性数据。

在实验验证方面，将主要采用理论证明与实验研究的方式验证参数化方案的实用性。

（3）f-CRU 模型方法

本研究利用参数化方案缩短原有 CRU 模型运行时间。从关键问题矩阵反演与矩阵指数入手，采用两个核心步骤解决相应问题：第一，将状态协方差与观测模型进行因式分解假设，目的为将非线性模型转化为难度系数低的线性子系统提高模型计算效率。将状态协方差与观测模型进行因式分解假设的方案是基于线性系统理论提出，分解后的线性子系统与非线性动态系统的局部特征存在相似性。第二，使用只允许交换具有相关特征空间的对称基矩阵的方式替代矩阵指数运算。特征向量根据此方法减少重复运算提升模型计算效率。基本原理为匹配相同特征空间的矩阵变换处理方法。

在本研究中，采用理论分析与试验研究为主的思路。f-CRU 模型同样需要执行插值、回归与外推三种任务实现不规则时间训练相关研究，其研究结果会与 CRU 模型及其它基线生成的实验结果进行对比得到模型性能的具体评估。

（4）CRU 模型投资市场应用

本研究重视对于 CRU 模型的训练得到相应参数。在实值输出时使用高斯负对数似然作为损失函数对模型进行训练，通过拟合符合高斯分布的概率密度函数使用最小化误差确定参数。在二进制输出时使用伯努利负对数似然函数，此

理论拥有良好的二元分类问题弥补高斯负对数似然的缺陷。

本研究拟采用数值仿真为主的研究思路确认 CRU 模型在投资市场价格预估领域是否拥有良好的预测效果，数据任务处理为外推任务的形式。

4. 本项目的特色与创新之处；

本课题的特色与创新之处总共有三点，总结如下：

（1）卡尔曼滤波器与 SDE 结合

本研究提出使用卡尔曼滤波器与线性 SDE 结合构建新型循环神经网络的研究新思路。CRU 模型理论框架提出丰富原有递归神经网络理论架构，在降低运行时间与提升模型建模准确率的两大模型设计目标中找到可行平衡点同时满足两种目标。

（2）矩阵指数替代

本课题提出转移矩阵新替代思路，即设置只允许交换具有相关特征空间的对称基矩阵简化运算，提升模型运算速度。本课题中矩阵指数运算被替代一定程度上限制模型建模准确率，但是仍然为降低矩阵指数的运行时间难题提供可行的解决思路。

（3）在投资市场中的应用研究

已有投资市场模型常用 LSTM 等模型对股票价格进行预测。本项目通过借鉴已有的投资市场价格预测模型提出新的预测模型，丰富神经网络模型在投资市场价格方面研究，为 CRU 模型提供新应用思路。

附件：

成员具体分工如下：

项目研究第一阶段对连续循环单元顶级会议论文进行研究，每人撰写一篇第三部分原理研究的总结文档。

XXX：原文背景内容要点总结，原论文对应 PPT 背景内容翻译

XXX：原文相关研究传统 RNN 与 RNN 时间序列部分总结

XXX：原文相关研究连续时间 RNN 与 Neural ODEs 部分总结

XXX：原文相关研究 Neural SDEs 与注意力机制部分总结

项目第二阶段为精读报告撰写阶段。

XXX：每人各五篇外文近三年相关研究内容总结概括

XXX：本项目研究的顶级会议论文正文部分内容总结、PPT 模型概述图模型特点概括、最终精读报告内容审核

XXX：虚拟货币价格数据集提供、精读报告图片绘制

XXX：成员分工、精读报告正文撰写、金价雀巢股价数据集提供、中文文献总结